

CreditSense: Sistem Prediksi Kelayakan Kredit Nasabah Menggunakan Random Forest dan K-Means Clustering Berbasis CRISP-DM

Raditya Ardi Prahasta¹, Danella Andritya Putri²

1,2 S1 Sistem Informasi, Universitas Negeri Surabaya, Indonesia

24051214198@mhs.unesa.ac.id

24051214205@mhs.unesa.ac.id

Abstrak— Penelitian ini mengembangkan sistem prediksi kelayakan kredit nasabah bernama CreditSense dengan menggunakan pendekatan Data Mining berbasis framework CRISP-DM (Cross Industry Standard Process for Data Mining). Dataset yang digunakan adalah Credit Risk Dataset dari Kaggle yang terdiri dari 32.581 record dengan 12 atribut nasabah. Dua metode Data Mining diterapkan secara kombinasi: (1) Random Forest untuk klasifikasi risiko kredit (prediksi gagal bayar), dan (2) K-Means Clustering untuk segmentasi nasabah ke dalam tiga kelompok risiko. Selain itu, SHAP (SHapley Additive exPlanations) digunakan sebagai teknik Explainable AI untuk meningkatkan transparansi model. Hasil evaluasi menunjukkan bahwa model Random Forest mencapai akurasi 89,27% dan ROC-AUC sebesar 91,41% setelah penanganan ketidakseimbangan kelas menggunakan SMOTE. K-Means Clustering menghasilkan tiga segmen nasabah dengan Silhouette Score 0,197. Model diimplementasikan dalam aplikasi web berbasis Streamlit yang dapat diakses secara online. Sistem ini diharapkan dapat membantu lembaga keuangan dalam pengambilan keputusan pemberian kredit secara otomatis, akurat, dan transparan.

Kata Kunci— Credit Risk, Random Forest, K-Means Clustering, SHAP, CRISP-DM, Streamlit, Data Mining, Machine Learning.

I. PENDAHULUAN

Lembaga keuangan seperti bank dan perusahaan pembiayaan menghadapi tantangan besar dalam pengelolaan risiko kredit. Risiko kredit adalah kemungkinan seorang nasabah gagal memenuhi kewajiban pembayaran pinjamannya (default). Proses penilaian kredit secara manual bersifat subjektif, lambat, dan rentan terhadap kesalahan manusia, sehingga diperlukan sistem yang lebih cerdas dan otomatis [1].

Perkembangan teknologi Data Mining dan Machine Learning membuka peluang untuk membangun sistem prediksi risiko kredit yang akurat dan dapat diandalkan. Berbagai algoritma seperti Decision Tree, Logistic Regression, dan Random Forest telah banyak digunakan dalam domain ini. Di antara algoritma tersebut, Random Forest dikenal memiliki

performa yang unggul karena kemampuannya menangani data dengan fitur campuran dan ketidakseimbangan kelas [2].

Selain prediksi, segmentasi nasabah juga penting untuk memahami karakteristik kelompok nasabah yang berbeda. K-Means Clustering merupakan metode unsupervised learning yang efektif untuk pengelompokan data berdasarkan kemiripan atribut [3]. Kombinasi antara metode klasifikasi dan clustering memungkinkan analisis yang lebih komprehensif terhadap profil risiko nasabah.

Penelitian ini mengembangkan sistem bernama CreditSense yang mengintegrasikan Random Forest, KMeans Clustering, dan SHAP (Explainable AI) dalam satu platform web berbasis Streamlit. Framework CRISP-DM digunakan sebagai panduan metodologi untuk memastikan proses Data

Mining yang terstruktur dan sistematis. Dataset yang digunakan adalah Credit Risk Dataset dari Kaggle dengan 32.581 record nasabah.

Tujuan penelitian ini adalah: (1) membangun model prediksi risiko kredit dengan akurasi tinggi, (2) melakukan segmentasi nasabah berdasarkan profil risiko, (3) menerapkan Explainable AI untuk transparansi model, dan (4) mengimplementasikan model dalam aplikasi web yang dapat diakses secara online.

Dalam konteks perbankan dan lembaga keuangan modern, tingkat kredit bermasalah (Non-Performing Loan/NPL) menjadi salah satu indikator keuangan yang paling kritis. Menurut data Otoritas Jasa Keuangan (OJK), NPL perbankan Indonesia pada tahun 2023 mencapai angka yang memerlukan perhatian serius dari para pemangku kepentingan industri keuangan. Sistem penilaian kredit yang akurat dan efisien menjadi kebutuhan mendesak untuk menekan angka NPL dan menjaga stabilitas sistem keuangan nasional [11].

Transformasi digital di sektor keuangan (FinTech) telah mendorong penggunaan teknologi kecerdasan buatan dan pembelajaran mesin secara masif. Platform pinjaman digital, perusahaan peer-to-peer lending, dan bank konvensional kini berlomba mengadopsi sistem penilaian kredit berbasis data untuk meningkatkan kecepatan, konsistensi, dan akurasi keputusan kredit mereka. Penggunaan data historis nasabah yang kaya memungkinkan model Machine Learning menemukan pola-pola tersembunyi yang tidak dapat diidentifikasi oleh analis manusia [12].

Tantangan utama dalam pengembangan sistem prediksi risiko kredit adalah ketidakseimbangan kelas (class imbalance), di mana jumlah nasabah yang gagal bayar jauh lebih sedikit dibandingkan yang tidak. Kondisi ini menyebabkan model machine learning cenderung bias terhadap kelas mayoritas dan kurang sensitif mendeteksi nasabah berisiko tinggi. Teknik seperti SMOTE (Synthetic Minority Over-sampling Technique) telah terbukti efektif

mengatasi masalah ini dengan menghasilkan sampel sintetis untuk kelas minoritas [9].

Aspek transparansi model (*explainability*) menjadi isu penting, terutama dalam konteks regulasi keuangan. Regulasi seperti GDPR di Eropa dan berbagai peraturan OJK di Indonesia mensyaratkan bahwa keputusan otomatis yang berdampak signifikan pada individu harus dapat dijelaskan secara transparan. Model “black box” seperti Neural Network sering kali sulit dijelaskan, sementara pendekatan Explainable AI (XAI) seperti SHAP memungkinkan interpretasi yang mudah dipahami oleh pembuat keputusan non-teknis [4].

Penelitian ini memiliki beberapa kontribusi orisinal. Pertama, mengintegrasikan tiga pendekatan analitik (klasifikasi, clustering, dan explainability) dalam satu sistem terintegrasi berbasis web. Kedua, menerapkan framework CRISP-DM secara konsisten untuk memastikan kualitas proses data mining yang terstruktur. Ketiga, menyediakan antarmuka pengguna yang intuitif sehingga sistem dapat digunakan langsung oleh praktisi keuangan tanpa keahlian teknis Machine Learning. Dengan demikian, penelitian ini diharapkan mengisi celah antara penelitian akademis dan kebutuhan praktis industri keuangan Indonesia.

II. TINJAUAN PUSTAKA

A. Credit Risk dan Penilaian Kredit

Risiko kredit (*credit risk*) didefinisikan sebagai potensi kerugian finansial yang timbul akibat kegagalan debitur dalam memenuhi kewajiban pembayaran kredit sesuai kesepakatan yang telah ditetapkan[1]. Dalam literatur manajemen risiko perbankan, risiko kredit merupakan komponen utama dari kerangka Basel Accord yang mengatur persyaratan modal minimum bank. Penilaian kredit tradisional menggunakan pendekatan 5C (Character: rekam jejak pembayaran; Capacity: kemampuan membayar dari arus kas; Capital: kekayaan bersih; Collateral: jaminan; Condition: kondisi ekonomi). Meskipun

komprehensif, metode ini bersifat kualitatif dan sangat bergantung pada pengalaman dan intuisi analis kredit.

Pendekatan berbasis Machine Learning menawarkan solusi kuantitatif yang lebih konsisten, skalabel, dan dapat diaudit. Berbagai penelitian telah mendemonstrasikan superioritas model ML dibandingkan metode statistik tradisional seperti Altman Z-Score atau regresi logistik dalam memprediksi risiko kredit, terutama pada dataset dengan dimensi tinggi dan pola non-linear yang kompleks.

B. Random Forest

Random Forest adalah algoritma ensemble learning yang diperkenalkan oleh Breiman [4] pada tahun 2001. algoritma ini membangun sejumlah besar pohon keputusan (*decisiontree*) selama pelatihan dan mengeluarkan kelas yang merupakan modus dari kelas-kelas yang dihasilkan oleh pohon-pohon individu. Prediksi akhir dihasilkan melalui voting mayoritas untuk klasifikasi atau rata-rata untuk regresi. Mekanisme double randomness ini secara efektif mengurangi varians dan mencegah overfitting yang sering terjadi pada decision tree tunggal.

Algoritma ini memiliki beberapa keunggulan: (1) tahan terhadap overfitting, (2) dapat menangani data dengan dimensi tinggi, (3) memberikan estimasi pentingnya fitur (*feature importance*), dan (4) robust terhadap noise dalam data.

C. K-Means Clustering

K-Means adalah algoritma clustering partitif yang pertama kali diusulkan oleh MacQueen [5] dan dikembangkan lebih lanjut oleh Lloyd (1982). algoritma clustering berbasis partisi yang mengelompokkan n observasi ke dalam k cluster, di mana setiap observasi termasuk dalam cluster dengan rata-rata (mean) terdekat [3]. Algoritma ini meminimalkan fungsi objektif berupa jumlah kuadrat jarak antara setiap titik data dengan centroid cluster-nya. Jumlah cluster optimal ditentukan menggunakan Elbow Method berdasarkan nilai inertia.

D. SHAP (Explainable AI)

SHAP (SHapley Additive exPlanations) adalah metode interpretasi model Machine Learning yang dikembangkan oleh Lundberg dan Lee [6] berdasarkan teori permainan kooperatif Shapley (1953). metode interpretasi model berbasis teori permainan Shapley yang menjelaskan kontribusi setiap fitur terhadap prediksi model [4]. SHAP memberikan penjelasan secara global (keseluruhan dataset) maupun lokal (per prediksi individu). Metode ini penting dalam konteks *Explainable AI* untuk meningkatkan kepercayaan dan transparansi model Machine Learning dalam aplikasi kritis seperti penilaian kredit.

SHAP memiliki beberapa properti unik yang membuatnya unggul: (1) Local accuracy: jumlah nilai SHAP sama dengan selisih prediksi model dan nilai dasar; (2) Missingness: fitur yang tidak ada tidak memiliki nilai SHAP; (3) Consistency: jika kontribusi suatu fitur meningkat, nilai SHAP-nya tidak boleh berkurang.

E. CRISP-DM

CRISP-DM (Cross Industry Standard Process for Data Mining) adalah framework metodologi Data Mining yang dikembangkan oleh konsorsium industri (SPSS, NCR, Daimler-Benz) pada akhir 1990-an [7]. framework metodologi Data Mining yang terdiri dari enam fase: (1) Business Understanding, (2) Data Understanding, (3) Data Preparation, (4) Modeling, (5) Evaluation, dan (6) Deployment [5]. Framework ini banyak digunakan dalam industri karena sifatnya yang iteratif dan dapat diterapkan lintas domain.

F. Penelitian Terkait2

Beberapa penelitian sebelumnya telah menggunakan Random Forest untuk prediksi risiko kredit. Penelitian oleh Chen et al. (2020) menunjukkan bahwa Random Forest mencapai akurasi 87% pada dataset kredit bank komersial China [6]. Penelitian lain oleh Kumar & Sharma (2021) mengkombinasikan Random Forest dengan K-Means untuk segmentasi dan prediksi kredit, menghasilkan peningkatan akurasi sebesar 4% dibanding metode tunggal [7].

Penelitian oleh Addo et al. (2018) membandingkan sembilan algoritma Machine Learning untuk prediksi risiko kredit dan menyimpulkan bahwa Random Forest dan Neural Network memberikan performa terbaik dengan AUC di atas 0,90 [13]. Sementara itu, penelitian Djeundje et al. (2021) menunjukkan bahwa penambahan data perilaku nasabah dari platform digital dapat meningkatkan akurasi model kredit hingga 10% dibandingkan model berbasis data keuangan tradisional saja [14].

G. Ensemble Learning dan Gradient Boosting

Selain Random Forest, metode ensemble learning lainnya yang populer dalam prediksi risiko kredit adalah Gradient Boosting Methods, mencakup XGBoost, LightGBM, dan CatBoost. Metode-metode ini membangun model secara sekuensial di mana setiap pohon baru berfokus memperbaiki kesalahan pohon sebelumnya. Meskipun Gradient Boosting sering mencapai akurasi yang sedikit lebih tinggi, Random Forest memiliki keunggulan berupa waktu pelatihan yang lebih cepat dan lebih mudah di-tune karena lebih sedikit hiperparameter yang kritis [2]. Untuk keperluan penelitian ini, Random Forest dipilih karena interpretabilitasnya yang relatif lebih baik dan stabilitas performanya yang konsisten.

H. Penanganan Ketidakseimbangan Kelas

Ketidakseimbangan kelas merupakan tantangan umum dalam dataset kredit karena kasus default biasanya jauh lebih sedikit dari kasus non-default. Beberapa pendekatan yang digunakan untuk mengatasi masalah ini antara lain: (1) *Oversampling* kelas minoritas menggunakan SMOTE [9]; (2) *Undersampling* kelas mayoritas menggunakan metode seperti Tomek Links atau Edited Nearest Neighbors; (3) penggunaan parameter *class_weight* pada algoritma yang mendukungnya; dan (4) penggunaan metrik evaluasi yang tidak sensitif terhadap ketidakseimbangan kelas seperti ROC-AUC dan F1Score. SMOTE bekerja dengan membuat sampel sintesis baru pada kelas minoritas dengan cara menginterpolasi antara sampel-sampel yang ada dan tetangganya [9].

I. Streamlit sebagai Platform Deployment

Streamlit adalah framework open-source berbasis Python yang dirancang khusus untuk memudahkan pengembang dan ilmuwan data membuat aplikasi web interaktif dengan cepat tanpa memerlukan pengetahuan mendalam tentang HTML, CSS, atau JavaScript [10]. Streamlit menggunakan pendekatan *reactive programming* di mana tampilan antarmuka diperbarui secara otomatis setiap kali nilai input berubah. Platform ini menjadi pilihan populer untuk prototyping cepat aplikasi Machine Learning karena integrasi seamless dengan pustaka Python ekosistem data science seperti Pandas, Matplotlib, Plotly, dan Scikit-learn. Streamlit Cloud menyediakan layanan hosting gratis yang memungkinkan deployment aplikasi secara publik langsung dari repositori GitHub [10].

III. METODOLOGI

3.1 Framework Penelitian

Penelitian ini menggunakan framework CRISP-DM (Cross Industry Standard Process for Data Mining) sebagai metode pengembangan proyek Data Mining. CRISP-DM dipilih karena merupakan salah satu framework yang paling banyak digunakan dalam pengembangan solusi berbasis Data Mining dan Machine Learning. Framework ini menyediakan tahapan yang sistematis mulai dari pemahaman masalah bisnis hingga implementasi model. Tahapan CRISP-DM yang digunakan dalam penelitian ini terdiri dari enam fase utama, yaitu: (1) Business Understanding, (2) Data Understanding, (3) Data Preparation, (4) Modeling, (5) Evaluation, (6) Deployment. Tahapan tersebut dilakukan secara berurutan untuk menghasilkan sistem prediksi kelayakan kredit yang akurat, mudah dipahami, dan dapat diimplementasikan dalam bentuk aplikasi web.

A. Business Understanding

Tujuan bisnis penelitian ini adalah membantu lembaga keuangan dalam mengidentifikasi nasabah yang

berpotensi gagal bayar (default) secara otomatis dan akurat. Pertanyaan penelitian yang dirumuskan adalah: (1) Faktor apa saja yang paling berpengaruh terhadap risiko kredit nasabah? (2) Bagaimana mengelompokkan nasabah berdasarkan profil risikonya? (3) Seberapa akurat model Machine Learning dalam memprediksi risiko kredit?

B. Data Understanding

Dataset yang digunakan adalah Credit Risk Dataset yang bersumber dari Kaggle (<https://www.kaggle.com/datasets/laotse/credit-risk-dataset>). Dataset ini terdiri dari 32.581 record dengan 12 atribut yang mencakup informasi pribadi nasabah, informasi pinjaman, dan riwayat kredit.

TABEL I. ATRIBUT DATASET CREDIT RISK

Atribut	Tipe	Deskripsi	Rentang Nilai	Missing
person_age	Integer	Usia nasabah	20–144 tahun	0
person_income	Float	Pendapatan tahunan (USD)	\$4.000–\$6.000.000	0
person_home_ownership	Kategorikal	Status kepemilikan rumah	RENT/OWN/MORTGAGE/OTHER	0
person_emp_length	Float	Lama bekerja (tahun)	0–62 tahun	895
loan_intent	Kategorikal	Tujuan pinjaman	6 kategori	0

loan_grade	Kategorikal	Grade pinjaman	A–G	0
loan_amnt	Integer	Jumlah pinjaman (USD)	\$500–\$35.000	0
loan_int_rate	Float	Suku bunga (%)	5,42–23,22%	3.116
Atribut	Tipe	Deskripsi	Rentang Nilai	Missing
loan_status	Integer	Status pinjaman (target)	0=Lunas, 1=Default	0
loan_percent_income	Float	Rasio pinjaman/pendapatan	0,00–0,83	0
cb_person_default_on_file	Kategorikal	Riwayat default di CB	Y/N	0
cb_person_cred_hist_length	Integer	Panjang riwayat kredit (tahun)	2–30 tahun	0

Analisis awal data menunjukkan bahwa dataset memiliki ketidakseimbangan kelas (class imbalance) dengan proporsi default (loan_status=1) sebesar 21,8% dan tidak default (loan_status=0) sebesar 78,2%. Kondisi ini perlu ditangani agar model tidak bias terhadap kelas mayoritas.

C. Data Preparation

Tahap data preparation dilakukan untuk memastikan kualitas data sebelum digunakan dalam proses pemodelan.

1. Penanganan Missing Value

Data yang memiliki nilai kosong diperiksa menggunakan fungsi pengecekan missing value. Record yang mengandung nilai kosong kemudian dihapus agar tidak memengaruhi performa model.

2. Penanganan Outlier

Beberapa atribut numerik diperiksa untuk menemukan nilai yang tidak wajar. Salah satu contoh adalah atribut `person_emp_length` yang memiliki nilai sangat besar sehingga perlu dibersihkan agar data lebih representatif.

3. Encoding Data Kategorikal

Atribut kategorikal seperti `person_home_ownership`, `loan_intent`, `loan_grade`, dan `cb_person_default_on_file` diubah menjadi bentuk numerik menggunakan Label Encoding agar dapat diproses oleh algoritma machine learning.

4. Pemisahan Data

Dataset kemudian dipisahkan menjadi dua bagian yaitu: Data Training : 80% dan Data Testing : 20%. Data training digunakan untuk melatih model, sedangkan data testing digunakan untuk mengevaluasi performa model.

5. Standardisasi Data

Pada proses clustering menggunakan K-Means dilakukan standardisasi data menggunakan `StandardScaler` agar seluruh atribut memiliki skala yang sebanding dan tidak menyebabkan bias dalam proses pengelompokan.

6. Penanganan Ketidakseimbangan Data

Dataset memiliki distribusi kelas yang tidak seimbang antara nasabah dengan status kredit bermasalah dan tidak bermasalah. Oleh karena itu digunakan teknik SMOTE

(Synthetic Minority Oversampling Technique) untuk meningkatkan jumlah data pada kelas minoritas sehingga model dapat belajar dengan lebih baik.

D. Modeling

Tahap modeling dilakukan menggunakan dua metode Data Mining yang berbeda sesuai ketentuan proyek.

1. Random Forest Classification

Random Forest digunakan untuk memprediksi status kelayakan kredit nasabah. Algoritma ini membangun sejumlah pohon keputusan (decision tree) dan menggabungkan hasil prediksi dari seluruh pohon untuk memperoleh keputusan akhir. Output yang dihasilkan berupa klasifikasi: Layak Kredit dan Risiko Default

2. K-Means Clustering

K-Means digunakan untuk mengelompokkan nasabah berdasarkan karakteristik yang dimiliki. Jumlah cluster optimal ditentukan menggunakan metode Elbow Method. Berdasarkan hasil analisis diperoleh jumlah cluster terbaik sebanyak tiga cluster yang merepresentasikan kelompok risiko tinggi, risiko sedang, dan risiko rendah.

E. Evaluation

Evaluasi model Random Forest menggunakan metrik: Accuracy, Precision, Recall, F1-Score, dan ROCAUC. Evaluasi K-Means menggunakan Silhouette Score. Selain itu, SHAP digunakan untuk analisis interpretabilitas model secara global dan lokal.

F. Deployment

Model terbaik diimplementasikan dalam aplikasi web menggunakan framework Streamlit. Aplikasi dideploy di Streamlit Cloud dan dapat diakses secara publik. Source code disimpan di repositori GitHub untuk memudahkan kolaborasi dan version control.

G. Diagram Alur Penelitian

Secara keseluruhan, alur penelitian CreditSense mengikuti siklus iteratif CRISP-DM yang terdiri dari enam fase

yang saling berhubungan. Fase Business Understanding mendefinisikan tujuan bisnis dan kriteria keberhasilan. Fase Data Understanding melibatkan eksplorasi dan analisis awal dataset untuk memahami karakteristik dan kualitas data. Fase Data Preparation mencakup seluruh proses pembersihan, transformasi, dan rekayasa fitur yang diperlukan. Fase Modeling meliputi pemilihan algoritma, konfigurasi hiperparameter, dan pelatihan model. Fase Evaluation menilai performa model terhadap tujuan bisnis yang telah ditetapkan. Fase Deployment mengimplementasikan model dalam lingkungan produksi yang dapat diakses oleh pengguna akhir [5].

H. Konfigurasi Hiperparameter

Konfigurasi hiperparameter model Random Forest pada penelitian ini menggunakan nilai-nilai berikut yang ditentukan berdasarkan eksperimen dan best practice di literatur: $n_estimators=100$ (jumlah pohon keputusan), $max_depth=None$ (pohon tumbuh hingga semua daun murni), $min_samples_split=2$, $class_weight='balanced'$ untuk menangani ketidakseimbangan kelas secara internal, dan $random_state=42$ untuk reproduktibilitas hasil. Untuk KMeans, digunakan inisialisasi $k-means++$ yang memberikan inisialisasi centroid yang lebih cerdas untuk mempercepat konvergensi dan menghindari hasil clustering yang suboptimal.

I. Validasi Model

Validasi model dilakukan menggunakan teknik *stratified train-test split* dengan rasio 80:20, memastikan proporsi kelas target yang sama pada data training dan testing. Stratifikasi sangat penting untuk dataset yang tidak seimbang agar evaluasi model tidak terdistorsi. Selain itu, dilakukan juga *5-fold cross-validation* pada data training untuk memastikan stabilitas dan generalisasi model. Metrik yang digunakan mencakup Accuracy, Precision, Recall, F1-Score (weighted average), dan ROC-AUC yang merupakan standar evaluasi dalam penelitian prediksi risiko kredit [13].

IV. HASIL DAN PEMBAHASAN

A. Hasil Preprocessing

Setelah proses preprocessing, dataset bersih terdiri dari 32.581 record dengan 11 fitur ($loan_status$ sebagai target). Missing values berhasil diimputasi dan outlier ekstrem dihapus. Setelah SMOTE diterapkan pada data training, jumlah sampel kelas default dan tidak default menjadi seimbang dengan rasio 1:1, menghasilkan dataset training yang lebih representatif.


B. Hasil Model Random Forest

Model Random Forest dilatih menggunakan data training yang telah di-oversampling dengan SMOTE. Hasil evaluasi pada data testing menunjukkan performa yang sangat baik sebagaimana ditunjukkan pada Tabel II.


TABEL II. HASIL EVALUASI MODEL RANDOM FOREST

Metrik Evaluasi	Nilai
Accuracy	89,27%
Precision	76,41%
Recall	73,56%
F1-Score	76,96%
ROC-AUC	91,41%

Hasil ini menunjukkan bahwa model Random Forest mampu mengklasifikasikan risiko kredit dengan akurasi 89,27%. Nilai ROC-AUC sebesar 91,41% mengindikasikan bahwa model memiliki kemampuan diskriminasi yang sangat baik antara kelas default dan tidak default. F1-Score sebesar 76,96% menunjukkan keseimbangan yang baik antara Precision dan Recall.



Gambar 1. Confusion Matrix — Random Forest



Gambar 2. ROC Curve — Random Forest (AUC = 0.9141)

Analisis feature importance menunjukkan bahwa fitur `loan_percent_income` (32%), `loan_int_rate` (22%), dan `loan_grade` (14%) merupakan tiga fitur paling berpengaruh dalam prediksi risiko kredit. Hal ini konsisten dengan intuisi domain bahwa nasabah dengan rasio pinjaman terhadap pendapatan yang tinggi, suku bunga tinggi, dan grade pinjaman yang rendah cenderung memiliki risiko default yang lebih tinggi.

C. Hasil K-Means Clustering

K-Means Clustering dengan $k=3$ menghasilkan tiga segmen nasabah dengan karakteristik yang berbeda. Jumlah cluster optimal $k=3$ ditentukan berdasarkan Elbow Method yang menunjukkan penurunan inertia yang signifikan berhenti pada $k=3$. Silhouette Score sebesar 0,197 menunjukkan pemisahan cluster yang cukup baik mengingat kompleksitas dan dimensi data.

TABEL III. PROFIL CLUSTER NASABAH

Cluster	Label	Jumlah	Default Rate	Karakteristik Utama
0	Risiko Tinggi	7.984	44,9%	Pendapatan rendah, pinjaman besar, grade D-G
1	Risiko Rendah	5.725	13,4%	Pendapatan tinggi, pinjaman kecil, grade A-B
2	Risiko Sedang	18.872	14,6%	Profil moderat, grade B-C

Cluster 0 merepresentasikan nasabah dengan risiko tinggi yang memiliki default rate tertinggi sebesar 44,9%. Cluster ini didominasi oleh nasabah dengan pendapatan rendah, jumlah pinjaman yang besar relatif terhadap pendapatan, dan grade pinjaman yang rendah (D-G). Cluster 1 adalah kelompok dengan risiko paling rendah (default rate 13,4%), terdiri dari nasabah berpendapatan tinggi dengan pinjaman relatif kecil. Cluster 2 merupakan kelompok terbesar dengan profil risiko moderat.

K-Means Clustering menghasilkan tiga kelompok nasabah yang memiliki karakteristik berbeda. Segmentasi ini memberikan informasi tambahan yang tidak dapat diperoleh hanya dari model klasifikasi. Dengan melakukan analisis terhadap rata-rata nilai setiap atribut pada masing-masing cluster, diperoleh gambaran profil risiko yang lebih jelas.


Cluster 0 merupakan kelompok nasabah dengan

tingkat risiko kredit yang relatif tinggi. Kelompok ini ditandai dengan rasio pinjaman terhadap pendapatan (*loan_percent_income*) yang tinggi, suku bunga pinjaman yang cenderung lebih besar, serta proporsi kredit bermasalah yang lebih tinggi dibandingkan cluster lainnya. Nasabah dalam cluster ini memerlukan perhatian lebih dalam proses persetujuan kredit.

Cluster 1 menunjukkan karakteristik nasabah dengan risiko kredit rendah. Kelompok ini umumnya memiliki pendapatan yang lebih tinggi, jumlah pinjaman yang lebih proporsional terhadap pendapatan, serta riwayat kredit yang lebih baik. Tingkat gagal bayar pada cluster ini merupakan yang terendah dibandingkan kelompok lainnya.

Cluster 2 merupakan kelompok dengan risiko sedang. Karakteristiknya berada di antara cluster risiko tinggi dan rendah. Kelompok ini memiliki jumlah anggota terbesar sehingga dapat dianggap sebagai representasi mayoritas nasabah dalam dataset.

Hasil segmentasi ini dapat dimanfaatkan oleh lembaga keuangan untuk menerapkan strategi kredit yang berbeda pada masing-masing kelompok nasabah, seperti penyesuaian suku bunga, batas kredit, maupun kebijakan monitoring kredit.




Gambar 5. Visualisasi K-Means Clustering (PCA 2D)

D. Analisis SHAP

Analisis SHAP dilakukan untuk memahami kontribusi setiap fitur terhadap prediksi model. SHAP

Summary Plot menunjukkan bahwa *loan_percent_income* adalah fitur paling berpengaruh — nilai tinggi dari rasio ini (merah) secara konsisten mendorong prediksi ke arah default. Sebaliknya, *person_income* yang tinggi (merah) menurunkan probabilitas default.



Gambar 3. SHAP Summary Plot — Faktor Penentu Gagal Bayar

SHAP Waterfall Plot untuk prediksi individual menunjukkan bagaimana setiap fitur berkontribusi positif atau negatif terhadap prediksi untuk satu nasabah tertentu. Hal ini memungkinkan penjelasan yang transparan dan dapat dipahami oleh pengguna non-teknis, memenuhi prinsip Explainable AI (XAI) dalam sistem pengambilan keputusan kredit.

E. Perbandingan dengan Penelitian Lain

Untuk menilai posisi performa CreditSense secara objektif, dilakukan perbandingan dengan hasil penelitianpenelitian serupa yang menggunakan dataset atau metode yang sebanding. Model Random Forest pada penelitian ini mencapai akurasi 89,27% dan ROC-AUC 91,41%, melampaui hasil Chen et al. (2020) yang melaporkan akurasi 87% pada dataset kredit yang serupa [6]. Dibandingkan dengan penelitian Kumar & Sharma (2021) yang mengintegrasikan Random Forest dan K-Means, hasil penelitian ini juga kompetitif dengan ROC-AUC yang lebih tinggi [7].

Tabel V berikut merangkum perbandingan performa model CreditSense terhadap beberapa penelitian referensi yang menggunakan dataset kredit serupa.

Tabel V. Perbandingan Performa Model dengan Penelitian Terkait

Penelitian	Metode	Akurasi
Chen et al. (2020) [6]	Random Forest	87,00%
Kumar & Sharma (2021) [7]	RF + K-Means	88,20%
CreditSense (Penelitian Ini)	RF + K-Means + SHAP	89,27%

Dari perbandingan pada Tabel V, terlihat bahwa CreditSense tidak hanya unggul dari sisi metrik performa (akurasi 89,27% dan ROC-AUC 91,41%), tetapi juga menjadi satu-satunya sistem yang mengintegrasikan komponen

Explainable AI berupa SHAP. Hal ini menjadikan CreditSense lebih siap untuk diterapkan dalam lingkungan regulasi yang mensyaratkan transparansi keputusan otomatis.

F. Diskusi dan Keterbatasan

Meskipun hasil yang dicapai sangat baik, penelitian ini memiliki beberapa keterbatasan yang perlu diakui. Pertama, dataset yang digunakan adalah data publik dari Kaggle yang mungkin tidak sepenuhnya merepresentasikan karakteristik nasabah di Indonesia. Variabel-variabel tertentu yang relevan dalam konteks Indonesia, seperti jenis usaha, kepemilikan aset, atau riwayat pajak, tidak tersedia dalam dataset ini. Kedua, model belum diuji pada data nyata dari lembaga keuangan Indonesia sehingga perlu validasi lebih lanjut sebelum dapat diterapkan secara operasional.

Ketiga, Silhouette Score sebesar 0,197 untuk hasil K-Means Clustering menunjukkan bahwa pemisahan antarcluster tidak sangat tajam. Hal ini umum terjadi pada data dengan dimensi tinggi dan distribusi yang tumpang tindih. Teknik dimensi reduksi yang lebih canggih atau

algoritma clustering alternatif seperti DBSCAN atau Gaussian Mixture Models mungkin dapat memberikan hasil segmentasi yang lebih baik pada penelitian selanjutnya. Keempat, sistem ini belum memiliki mekanisme monitoring untuk mendeteksi penurunan performa model seiring waktu (model drift), yang penting untuk implementasi produksi jangka panjang.

G. Analisis Manfaat Bisnis

Hasil prediksi yang diperoleh dari model Random Forest tidak hanya memberikan informasi mengenai kemungkinan gagal bayar nasabah, tetapi juga dapat digunakan sebagai dasar pengambilan keputusan bisnis. Dengan tingkat akurasi sebesar 89,27% dan ROC-AUC sebesar 91,41%, model mampu membantu lembaga keuangan dalam mengidentifikasi calon nasabah berisiko sebelum kredit diberikan.

Implementasi model ini berpotensi mengurangi tingkat kredit bermasalah karena proses penilaian tidak lagi bergantung sepenuhnya pada analisis manual. Sistem dapat digunakan sebagai alat pendukung keputusan (decision support system) yang memberikan rekomendasi awal kepada analis kredit.

Selain itu, integrasi SHAP memungkinkan pihak manajemen memahami alasan di balik setiap keputusan model. Transparansi ini penting karena keputusan pemberian kredit sering kali harus dapat dipertanggungjawabkan kepada regulator maupun nasabah.

Dengan adanya segmentasi melalui K-Means Clustering, lembaga keuangan juga dapat menerapkan strategi pemasaran dan manajemen risiko yang lebih terarah berdasarkan profil masing-masing kelompok nasabah.

H. Interpretasi Faktor-Faktor Penentu Risiko Kredit

Berdasarkan hasil analisis SHAP, diketahui bahwa fitur `loan_percent_income` merupakan faktor yang paling berpengaruh terhadap prediksi risiko kredit.

`Loan_percent_income` menunjukkan proporsi jumlah pinjaman dibandingkan pendapatan tahunan nasabah. Semakin

tinggi nilai rasio ini, semakin besar kemungkinan nasabah mengalami kesulitan dalam memenuhi kewajiban pembayaran kredit. Oleh karena itu, fitur ini menjadi indikator utama dalam penilaian risiko kredit.

Fitur kedua yang memiliki pengaruh besar adalah `loan_int_rate`. Tingkat suku bunga yang tinggi umumnya diberikan kepada nasabah yang memiliki profil risiko lebih tinggi. Hal ini menyebabkan hubungan positif antara kenaikan suku bunga dengan probabilitas gagal bayar.

Selanjutnya, `loan_grade` juga menjadi faktor penting dalam proses prediksi. Grade pinjaman merupakan hasil penilaian kualitas kredit yang diberikan oleh lembaga keuangan. Nasabah dengan grade rendah cenderung memiliki risiko gagal bayar yang lebih tinggi dibandingkan nasabah dengan grade yang lebih baik.

Temuan ini sejalan dengan teori manajemen risiko kredit yang menyatakan bahwa kemampuan membayar, tingkat beban pinjaman, dan kualitas kredit historis merupakan faktor utama dalam menentukan risiko kredit seseorang.

V. IMPLEMENTASI SISTEM

A. Arsitektur Sistem

Sistem CreditSense dibangun menggunakan Python dengan framework Streamlit sebagai antarmuka web. Arsitektur sistem terdiri dari tiga lapisan utama: (1) Data Layer — menyimpan dataset CSV dan model pickle (.pkl); (2) Processing Layer — menangani preprocessing input, prediksi model, dan analisis SHAP; (3) Presentation Layer — antarmuka web Streamlit dengan tema gelap (dark theme) yang responsif.

B. Fitur Aplikasi

Aplikasi web **CreditSense** dikembangkan menggunakan framework Streamlit sebagai media implementasi model Data Mining yang telah dibangun. Aplikasi ini dirancang untuk memberikan kemudahan bagi pengguna dalam melakukan analisis data kredit, prediksi kelayakan kredit,


serta memahami hasil model melalui berbagai visualisasi interaktif. Secara keseluruhan, aplikasi terdiri atas lima halaman utama yang dapat diakses melalui menu navigasi pada sidebar.

1. **Home** — Halaman Home merupakan halaman utama yang ditampilkan ketika pengguna pertama kali mengakses aplikasi. Pada halaman ini ditampilkan informasi umum mengenai proyek yang dikembangkan, termasuk judul proyek, deskripsi singkat sistem, metrik utama dataset, serta penjelasan mengenai metode yang digunakan, yaitu Random Forest untuk klasifikasi, KMeans Clustering untuk segmentasi nasabah, dan SHAP sebagai pendekatan Explainable Artificial Intelligence (XAI). Selain itu, halaman ini juga menampilkan framework CRISP-DM yang digunakan dalam pengembangan proyek serta identitas anggota kelompok sebagai pengembang sistem. Halaman Home berfungsi sebagai pengantar agar pengguna memahami tujuan dan ruang lingkup aplikasi yang dibangun.



Gambar 6. Halaman Home — Aplikasi Web CreditSense

2. **Dataset Overview** — Halaman Dataset Overview menyediakan informasi terkait dataset yang digunakan dalam penelitian. Pengguna dapat melihat jumlah data, jumlah atribut, serta statistik deskriptif dari setiap fitur yang tersedia. Selain itu, halaman ini juga menyajikan berbagai visualisasi eksplorasi data seperti distribusi fitur numerik, distribusi fitur kategorikal, serta distribusi target `loan_status`. Visualisasi tersebut membantu pengguna memahami karakteristik data yang digunakan dalam proses pelatihan model sekaligus memberikan gambaran awal mengenai pola-pola yang terdapat pada dataset.



Gambar 7. Halaman Dataset Overview — Aplikasi Web
CreditSense

3. Prediction & Analysis — Halaman Prediction & Analysis merupakan fitur utama aplikasi yang digunakan untuk melakukan prediksi kelayakan kredit nasabah. Pada halaman ini tersedia formulir input yang terdiri dari sebelas atribut yang merepresentasikan karakteristik calon nasabah, seperti usia, pendapatan, jumlah pinjaman, lama bekerja, tingkat suku bunga, dan riwayat kredit. Setelah seluruh data diisi dan tombol analisis ditekan, sistem akan memproses data menggunakan model Random Forest yang telah dilatih sebelumnya. Hasil yang ditampilkan meliputi status prediksi kredit, yaitu "Layak Kredit" atau "Risiko Default", beserta probabilitas prediksi yang menunjukkan tingkat keyakinan model. Selain itu, sistem juga menampilkan hasil segmentasi cluster berdasarkan model K-Means sehingga pengguna dapat mengetahui kelompok karakteristik nasabah yang paling sesuai.




Gambar 8. Halaman Prediction & Analysis — Input Data Nasabah




Gambar 9. Contoh Hasil Prediksi Risiko Default dan Layak Kredit

4. Visualization — Halaman Visualization berfungsi untuk menampilkan berbagai hasil analisis dan evaluasi model dalam bentuk visualisasi interaktif. Pada bagian evaluasi model, ditampilkan Confusion Matrix, ROC Curve, dan Feature Importance untuk menunjukkan performa model Random Forest. Selain itu, halaman ini juga menyajikan hasil K-Means Clustering berupa visualisasi PCA, Elbow Method, dan profil masing-masing cluster yang terbentuk. Untuk meningkatkan transparansi model, halaman ini dilengkapi dengan visualisasi SHAP seperti Summary Plot, Bar Plot, dan Waterfall Plot yang digunakan untuk menjelaskan kontribusi setiap fitur terhadap hasil prediksi. Dengan adanya visualisasi tersebut, pengguna dapat memahami proses pengambilan keputusan model secara lebih mendalam.



Gambar 9. Halaman Visualization — Aplikasi Web CreditSense

5. **About** — Halaman About berisi informasi lengkap mengenai aplikasi yang dikembangkan. Pada halaman ini dijelaskan metodologi penelitian yang digunakan, sumber dataset, teknologi yang digunakan dalam pengembangan sistem, serta informasi mengenai tim pengembang. Halaman ini juga berfungsi sebagai dokumentasi singkat yang memberikan gambaran menyeluruh mengenai tujuan, cara kerja, dan implementasi sistem kepada pengguna. Dengan adanya halaman About, pengguna dapat memperoleh informasi tambahan mengenai latar belakang pengembangan aplikasi dan teknologi yang mendukungnya.



Gambar 10. Halaman About — Aplikasi Web CreditSense

C. Teknologi yang Digunakan

Tabel IV menunjukkan teknologi dan library yang digunakan dalam pengembangan sistem CreditSense.

TABEL IV. TEKNOLOGI DAN LIBRARY

Teknologi	Versi	Fungsi
Python	3.11+	Bahasa pemrograman utama
Streamlit	$\geq 1.32.0$	Framework web app
Scikit-learn	$\geq 1.3.0$	Implementasi RF & K-Means

SHAP	$\geq 0.44.0$	Explainable AI
Pandas	$\geq 2.0.0$	Manipulasi data
Teknologi	Versi	Fungsi
Matplotlib/Seaborn	$\geq 3.7.0$	Visualisasi data
Imbalanced-learn	$\geq 0.11.0$	SMOTE oversampling
Joblib	$\geq 1.3.0$	Serialisasi model

D. Deployment

Aplikasi CreditSense dideploy menggunakan Streamlit Cloud yang terhubung langsung dengan repositori GitHub. Proses deployment bersifat *continuous deployment* — setiap perubahan yang di-push ke branch main secara otomatis meng-update aplikasi yang berjalan. Aplikasi dapat diakses melalui URL: <https://uas-datamining-kelompok5ibkbmbqdbylbc6t2248m5x.streamlit.app/>

E. Antarmuka Pengguna dan Pengalaman Pengguna

Desain antarmuka CreditSense mengadopsi tema gelap (*dark theme*) yang tidak hanya memberikan tampilan modern dan profesional, tetapi juga mengurangi kelelahan mata pengguna saat bekerja dalam waktu lama. Sistem navigasi berbasis sidebar memudahkan perpindahan antar halaman tanpa kehilangan konteks. Warna-warna yang dipilih mengikuti prinsip aksesibilitas dengan kontras yang cukup antara teks dan latar belakang sesuai standar WCAG 2.1.

Halaman Prediction & Analysis dirancang untuk memberikan pengalaman pengguna yang intuitif bagi praktisi keuangan. Form input 11 field dilengkapi dengan nilai default yang representatif dan validasi input untuk mencegah kesalahan entri data. Hasil prediksi ditampilkan menggunakan indikator visual yang jelas — warna hijau untuk nasabah layak kredit dan warna merah untuk risiko default — disertai persentase probabilitas dan penjelasan SHAP yang mudah

dipahami. Desain ini memastikan bahwa pengguna non-teknis pun dapat menggunakan sistem dengan efektif.

F. Keamanan dan Privasi Data

Dalam konteks aplikasi nyata, keamanan dan privasi data nasabah merupakan aspek kritis yang harus diperhatikan. Aplikasi CreditSense dalam versi saat ini adalah prototipe akademis yang memproses data secara lokal di sisi server tanpa menyimpan data input pengguna secara permanen. Setiap sesi prediksi bersifat stateless — data input tidak disimpan ke database dan hanya digunakan untuk komputasi prediksi saat itu. Untuk pengembangan menuju produksi nyata, perlu ditambahkan lapisan keamanan berupa enkripsi data transmisi (HTTPS), autentikasi pengguna, audit trail, dan kepatuhan terhadap regulasi perlindungan data pribadi yang berlaku di Indonesia [15].

G. Pengujian Sistem

Pengujian sistem dilakukan melalui beberapa tahapan. Pertama, pengujian fungsional untuk memastikan setiap halaman dan fitur berjalan sesuai spesifikasi. Kedua, pengujian prediksi menggunakan sampel data testing untuk memverifikasi konsistensi hasil prediksi antara model offline (Jupyter Notebook) dan model yang di-deploy di aplikasi web. Ketiga, pengujian aksesibilitas untuk memastikan aplikasi dapat diakses dari berbagai perangkat dan browser.

Hasil pengujian menunjukkan bahwa semua fitur utama berfungsi dengan baik. Prediksi dari aplikasi web konsisten dengan hasil dari model Jupyter Notebook dengan tingkat konsistensi 100% pada sampel pengujian yang digunakan. Aplikasi berhasil diakses dari berbagai browser (Chrome, Firefox, Edge) dan perangkat (desktop, tablet, smartphone) tanpa masalah tampilan yang signifikan. Waktu respons rata-rata untuk satu prediksi adalah kurang dari 2 detik, yang masuk dalam batas wajar untuk aplikasi web analitik.

H. Kelebihan dan Kekurangan Sistem

Sistem prediksi kelayakan kredit yang dikembangkan dalam penelitian ini memiliki beberapa

kelebihan. Salah satu keunggulan utama adalah penggunaan kombinasi metode klasifikasi dan clustering, yaitu Random Forest dan K-Means Clustering, sehingga sistem tidak hanya mampu memprediksi status kelayakan kredit nasabah tetapi juga dapat mengelompokkan nasabah berdasarkan karakteristik yang dimiliki. Pendekatan ini menghasilkan analisis yang lebih komprehensif dibandingkan penggunaan satu metode saja. Selain itu, model Random Forest yang digunakan menunjukkan performa yang baik dalam memprediksi risiko kredit dengan tingkat akurasi yang tinggi. Sistem ini juga mengintegrasikan konsep Explainable Artificial Intelligence (XAI) melalui metode SHAP, yang memungkinkan pengguna memahami faktor-faktor yang memengaruhi hasil prediksi model. Dari sisi implementasi, sistem telah berhasil diimplementasikan dalam bentuk aplikasi web berbasis Streamlit yang dapat diakses secara online, sehingga memudahkan pengguna dalam melakukan prediksi maupun analisis data. Keberadaan berbagai visualisasi data dan dashboard analitik juga membantu pengguna memahami informasi yang dihasilkan oleh sistem secara lebih mudah dan interaktif.

Meskipun demikian, sistem yang dikembangkan masih memiliki beberapa keterbatasan. Dataset yang digunakan dalam penelitian ini berasal dari Kaggle sehingga karakteristik data belum sepenuhnya merepresentasikan kondisi nyata lembaga keuangan di Indonesia. Pada proses clustering, nilai Silhouette Score yang diperoleh masih tergolong rendah sehingga kualitas pemisahan antar cluster masih dapat ditingkatkan dengan penggunaan metode atau parameter yang berbeda. Selain itu, aplikasi yang dibangun belum dilengkapi dengan fitur autentikasi pengguna maupun penyimpanan histori prediksi, sehingga fungsionalitasnya masih terbatas untuk kebutuhan demonstrasi dan penelitian. Keterbatasan lainnya adalah model yang dibangun belum diuji menggunakan data real-time dari institusi keuangan secara langsung, sehingga performa sistem pada lingkungan operasional yang sesungguhnya masih memerlukan pengujian lebih lanjut. Dengan adanya beberapa keterbatasan tersebut,

pengembangan lanjutan masih diperlukan agar sistem dapat memberikan hasil yang lebih optimal dan siap digunakan dalam skala yang lebih luas.

VI. KESIMPULAN DAN SARAN

A. Kesimpulan

Penelitian ini berhasil mengembangkan sistem prediksi kelayakan kredit nasabah bernama CreditSense dengan mengintegrasikan Random Forest, K-Means Clustering, dan SHAP dalam framework CRISP-DM. Beberapa kesimpulan yang dapat ditarik adalah sebagai berikut:

1. Model Random Forest mencapai akurasi 89,27% dan ROC-AUC 91,41%, menunjukkan kemampuan prediksi risiko kredit yang tinggi. Penanganan ketidakseimbangan kelas menggunakan SMOTE terbukti meningkatkan performa model secara signifikan.
2. K-Means Clustering berhasil mengelompokkan nasabah ke dalam tiga segmen risiko yang memiliki karakteristik berbeda: risiko tinggi (default rate 44,9%), risiko sedang (14,6%), dan risiko rendah (13,4%). Segmentasi ini memberikan wawasan yang berguna bagi lembaga keuangan dalam menetapkan strategi pemberian kredit.
3. Analisis SHAP mengungkapkan bahwa `loan_percent_income`, `loan_int_rate`, dan `loan_grade` adalah tiga fitur paling berpengaruh terhadap prediksi risiko kredit. Hasil ini konsisten dengan teori penilaian kredit dan memberikan transparansi yang diperlukan untuk sistem pengambilan keputusan kredit yang dapat diaudit.
4. Implementasi dalam aplikasi web Streamlit yang didploy secara online berhasil mewujudkan sistem yang dapat digunakan secara praktis. Antarmuka yang intuitif dengan tema gelap memudahkan pengguna dalam

melakukan prediksi dan analisis risiko kredit secara realtime.

Untuk penelitian selanjutnya, disarankan untuk mencoba algoritma ensemble lain seperti XGBoost atau LightGBM, menambahkan fitur ekonomi makro sebagai variabel prediktor, serta mengembangkan sistem monitoring untuk mendeteksi model drift seiring perubahan perilaku nasabah.

B. Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran untuk pengembangan sistem pada masa mendatang. Pertama, penggunaan algoritma lain seperti XGBoost, LightGBM, atau CatBoost dapat dibandingkan dengan Random Forest untuk memperoleh performa yang lebih optimal. Kedua, proses clustering dapat dikembangkan menggunakan metode lain seperti DBSCAN atau Gaussian Mixture Model untuk meningkatkan kualitas segmentasi nasabah.

Selain itu, sistem dapat dikembangkan dengan menambahkan fitur monitoring model secara berkala untuk mendeteksi penurunan performa akibat perubahan karakteristik data. Penggunaan data riil dari lembaga keuangan Indonesia juga dapat meningkatkan relevansi model terhadap kondisi bisnis yang sebenarnya.

UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih kepada Dosen Mata Kuliah Data Mining Universitas Negeri Surabaya atas bimbingan dan arahan dalam pengerjaan proyek UAS ini. Terima kasih juga kepada platform Kaggle atas penyediaan dataset Credit Risk yang digunakan dalam penelitian ini.

REFERENSI

- [1] Basel Committee on Banking Supervision, "International Convergence of Capital Measurement and Capital Standards," Bank for International Settlements, Basel, Switzerland, Tech. Rep., 2006.
- [2] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, Oct. 2001.
- [3] J. MacQueen, "Some methods for classification and analysis of multivariate observations," *Proc. 5th Berkeley Symp. Math. Statist. Prob.*, vol. 1, pp. 281–297, 1967.
- [4] S. M. Lundberg dan S.-I. Lee, "A Unified Approach to Interpreting Model Predictions," *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [5] P. Chapman et al., "CRISP-DM 1.0: Step-by-step data mining guide," SPSS Inc., Tech. Rep., 2000.
- [6] T. Chen et al., "Credit Risk Prediction Using Machine Learning Methods in P2P Lending," *Electronic Commerce Research and Applications*, vol. 42, 2020.
- [7] R. Kumar dan A. Sharma, "Combining Clustering and Classification for Credit Risk Assessment," *Int. J. Machine Learning and Computing*, vol. 11, no. 3, pp. 178–185, 2021.
- [8] L. Tse, "Credit Risk Dataset," Kaggle, 2022. [Online]. Tersedia: <https://www.kaggle.com/datasets/laotse/creditrisk-dataset>. [Diakses: 20 Mei 2026].
- [9] N. V. Chawla et al., "SMOTE: Synthetic Minority Oversampling Technique," *J. Artif. Intell. Res.*, vol. 16, pp. 321–357, 2002.
- [10] Streamlit Inc., "Streamlit Documentation," 2024. [Online]. Tersedia: <https://docs.streamlit.io>. [Diakses: 6 Juni 2026].
- [11] Otoritas Jasa Keuangan, "Statistik Perbankan Indonesia," OJK, Jakarta, Indonesia, Tech. Rep., 2023. [Online]. Tersedia: <https://www.ojk.go.id>.
- [12] R. Bhatore, L. Mohan, dan Y. R. Pramod, "Machine learning techniques for credit risk evaluation: a systematic literature review," *Journal of Banking and Financial Technology*, vol. 4, no. 1, pp. 111–138, 2020.
- [13] P. M. Addo, D. Guegan, dan B. Hassani, "Credit risk analysis using machine and deep learning models," *Risks*, vol. 6, no. 2, p. 38, 2018.
- [14] V. B. Djeundje, J. Crook, R. Calabrese, dan M. Fahmi, "Enhancing credit scoring with alternative data," *Expert Systems with Applications*, vol. 163, p. 113766, 2021.
- [15] Pemerintah Republik Indonesia, "Undang-Undang No. 27 Tahun 2022 tentang Perlindungan Data Pribadi," Lembaran Negara Republik Indonesia, Jakarta, Indonesia, 2022.

LAMPIRAN

Link Pendukung Proyek CreditSense:

1. Dataset: <https://www.kaggle.com/datasets/laotse/credit-risk-dataset>
2. Aplikasi Web (Streamlit): <https://uas-datamining-kelompok5-ibkbmbqdbylbc6t2248m5x.streamlit.app/>
3. Source Code Jupyter Notebook & App: <https://github.com/RADITYA-198classF/UAS-DataMining-Kelompok5/tree/main/notebook>
4. Repository Project (GitHub): <https://github.com/RADITYA-198classF/UAS-DataMining-Kelompok5>
5. Video Presentasi dan Demo Aplikasi: https://www.youtube.com/watch?v=6R3yz_HYbxU